

Predição de carga da região sudeste do Brasil [★]

Diego Gomes Machado ^{**} João Pedro Muffato Nascimento ^{***}
Vinicius Raimundo Pires ^{****}

*Departamento de Engenharia Elétrica, Universidade Federal de São
João del-Rei, MG*

^{**} e-mail: *diego1000kl@gmail.com*

^{***} e-mail: *jpmuffato96@gmail.com*

^{****} e-mail: *vparanhospires@gmail.com*

Abstract: This document presents the report for Computational Assignment 2 of the Machine Learning Applied to Engineering course. The study continues the research using real data from the Brazilian National Electric System Operator (ONS) initiated in Assignment 1. A regression problem was formulated for hourly electrical load forecasting over a one-week or one-month horizon, employing regularized linear models (Lasso and Ridge) and hybrid machine learning models (Support Vector Regression). Model validation was performed using a temporal approach and evaluated through free (autoregressive) simulation. The work focuses on methodological rigor, reproducibility, and the analysis of the impact of regularization on time series.

Resumo: Este documento apresenta o relatório do Trabalho Computacional 2 da disciplina Machine Learning aplicado à Engenharia. O trabalho dá continuidade ao estudo com dados reais do Operador Nacional do Sistema Elétrico (ONS) iniciado no Trabalho 1. Foi formulado um problema de regressão para a previsão de carga elétrica horária de uma semana ou um mês, utilizando modelos lineares regularizados (Lasso e Ridge) e modelos híbridos (Regressão por Vetores de Suporte) de aprendizado de máquina. A validação dos modelos foi realizada por meio de uma abordagem temporal e avaliada de forma livre (autorregressiva). O foco está no rigor metodológico, reprodutibilidade e análise do impacto da regularização em séries temporais.

Keywords: Machine Learning; classification; regression; model validation; engineering applications.

Palavras-chaves: Aprendizado de máquina; classificação; regressão; validação de modelos; aplicações em engenharia.

1. INTRODUÇÃO

A previsão de carga elétrica é essencial para a operação segura e eficiente do Sistema Interligado Nacional (SIN), permitindo o planejamento otimizado da geração e transmissão de energia. Devido à complexidade e não linearidade dos dados, técnicas de aprendizado de máquina superam métodos estatísticos tradicionais. Este trabalho compara o desempenho dos modelos FROLS, Regressão Ridge após Lasso e SVM com algoritmo genético na previsão da carga do SIN, analisando suas vantagens e limitações.

2. OBJETIVOS

O objetivo central deste estudo consiste em modelar, validar e comparar o desempenho de diferentes algoritmos de aprendizado de máquina (*machine learning*) aplicados à curva de carga horária do SIN (Sistema Interconectado Nacional) brasileiro no ano de 2025. A partir de uma estrutura autorregressiva, o trabalho analisa como as diferentes características intrínsecas de cada método influenciam a propagação e a acumulação de erros ao longo do horizonte de projeção semanal.

[★] Disciplina Machine Learning aplicado à Engenharia, Curso de Engenharia Elétrica, Universidade Federal de São João del-Rei.

3. DEFINIÇÃO DO PROBLEMA

O problema foi estruturado como uma tarefa de regressão supervisionada. Dado um conjunto de características preditoras no instante t , denotado por X_t , o objetivo é estimar a variável contínua y_t , que representa a carga de energia medida em Megawatts (MW).

Diferente de uma abordagem puramente estática, a natureza temporal do problema exige que o modelo seja capaz de capturar a dinâmica do sistema. Para isso, o problema foi mapeado em um formato tabular adaptado para séries temporais, através da inclusão de defasagens (*lags*) da própria variável resposta e de variáveis exógenas financeiras, assumindo a forma funcional:

$$\hat{y}_t = f(y_{t-1}, y_{t-24}, PLD_{t-1}, H_t, M_t) \quad (1)$$

onde PLD_{t-1} representa o Preço de Liquidação das Diferenças defasado em uma hora, enquanto H_t e M_t representam variáveis categóricas associadas à hora do dia e ao mês do ano, respectivamente.

4. DADOS E PRÉ-PROCESSAMENTO

A base de dados foi construída a partir da fusão de dois conjuntos de dados públicos de 2025: o histórico de curvas de carga horária por subsistema e o histórico do PLD horário.

O pré-processamento consistiu nas seguintes etapas estruturadas:

- (1) **Alinhamento e Fusão (*Merge*):** União das bases via chaves temporais (DIA, HORA) e geográficas (submercado), filtrando exclusivamente o submercado SUDESTE.
- (2) **Tratamento de Consistência:** Eliminação de registros duplicados e ordenação cronológica estrita dos dados.
- (3) **Engenharia de Recursos (*Feature Engineering*):** Criação dos *lags* de primeira ordem ($t - 1$) e de ordem diária ($t - 24$) para a carga, além do *lag* de primeira ordem para o PLD.
- (4) **Codificação Categórica:** Transformação das variáveis temporais inteiras (Hora e Mês) em variáveis binárias através do método *One-Hot Encoding*, mitigando falsas relações de ordem linear no modelo.
- (5) **Particionamento Temporal:** Divisão dos dados na proporção 80% para treinamento e 20% para teste. Crucialmente, o parâmetro *shuffle* foi definido como falso para preservar a ordem cronológica e evitar o vazamento de dados do futuro (*data leakage*).
- (6) **Escalonamento:** Aplicação do *StandardScaler* para normalizar as distribuições das *features* com média zero e variância unitária, garantindo a convergência correta das penalizações do Lasso e Ridge.

Tabela 1. Amostra dos Dados da Curva de Carga Elétrica (2025)

SUBMERCADO	Carga	Mês	DIA	HORA
NORTE	7097.751	1	1	0
NORTE	7097.751	1	1	0
NORTE	7097.751	1	1	0
...	...	...	...	...
SUDESTE	42418.294	12	31	23
SUDESTE	42418.294	12	31	23
SUDESTE	42418.294	12	31	23




Figura 1. Histórico de carga das regiões do Brasil em 2025.




Figura 2. Dados estatísticos da carga do mesmo dia em cada mês na região sudeste.

A análise exploratória inicial do conjunto de dados, ilustrada nas Figuras 1, 2 e 3, fundamenta a delimitação do escopo geográfico deste trabalho. A Figura 1 apresenta o histórico de carga das regiões do Brasil ao longo do ano de 2025. Fica evidente no gráfico que o submercado Sudeste opera com magnitudes de demanda expressivamente superiores às demais regiões do SIN. Devido a esse volume dominante e à sua elevada importância econômica estratégica para o país, optou-se por filtrar a base de dados para focar exclusivamente na modelagem preditiva do subsistema Sudeste.




Figura 3. Curva de carga de uma semana típica da região sudeste.

Para compreender a dinâmica desse submercado, a Figura 3 apresenta a curva de carga de uma semana típica da região, evidenciando uma forte ciclicidade diária e intrasemanal. Complementarmente, a Figura 2 expõe os dados estatísticos da carga do mesmo dia em cada mês, revelando a variância sazonal da demanda ao longo do ano. Essas características temporais complexas justificam a necessidade da aplicação de modelos robustos de aprendizado de máquina capazes de capturar tais padrões.

5. MÉTODOS E FUNDAMENTOS ADOTADOS

5.1 FROLS

O *Forward Regression Orthogonal Least Squares* (FROLS) identifica sistemas não lineares via decomposição ortogonal. O método seleciona regressores significativos de forma iterativa, garantindo modelos parcimoniosos e interpretáveis ao focar na redução da variância dos dados.

Extensão Teórica: O Problema da Seleção de Estrutura Em modelos polinomiais ou não lineares generalizados, o número potencial de regressores cresce exponencialmente com o grau do polinômio e a quantidade de atrasos (*lags*). Selecionar apenas alguns termos relevantes entre centenas de combinações possíveis é um desafio combinatório clássico.

Modelos com termos excessivos sofrem de **superajuste** (*overfitting*) e perdem a capacidade de generalização. Por outro lado, modelos muito simples sofrem de **subajuste** (*underfitting*). O FROLS resolve esse problema através de uma abordagem *greedy* (gulosa) e incremental: em vez de testar todas as combinações, ele adiciona um regressor por vez — aquele que traz a maior contribuição para explicar a variância da saída do sistema — até que um critério de parada seja atingido.

Contextualização Matemática Considere que o modelo linear nos parâmetros (como o NARX polinomial após a expansão dos termos) possa ser escrito na forma matricial:

$$y = P\theta + \Xi \quad (2)$$

Onde:

- $y = [y(1), y(2), \dots, y(N)]^T$ é o vetor de saídas medidas ($N \times 1$).
- $\theta = [\theta_1, \theta_2, \dots, \theta_M]^T$ é o vetor de parâmetros a serem estimados ($M \times 1$).
- $P = [p_1, p_2, \dots, p_M]$ é a matriz de regressores ($N \times M$), onde cada coluna p_i representa um candidato a regressor (ex: $y(t-1)$, $u(t-2)$, $y(t-1)^2$).
- Ξ é o vetor de resíduos/erros ($N \times 1$).

5.1.2.1. A Decomposição Ortogonal Como os regressores originais em P costumam ser altamente correlacionados entre si, estimar os coeficientes diretamente pode gerar instabilidade numérica. O FROLS resolve isso transformando a matriz P em um conjunto de regressores mutuamente ortogonais W :

$$P = WA \quad (3)$$

Onde A é uma matriz triangular superior com uns na diagonal principal, e $W = [w_1, w_2, \dots, w_M]$ possui colunas ortogonais, ou seja, $w_i^T w_j = 0$ para $i \neq j$. O modelo reescrito em termos do espaço ortogonal torna-se:

$$y = Wg + \Xi \quad (4)$$

Onde g é o vetor de parâmetros no espaço ortogonal. Multiplicando ambos os lados por w_i^T , os parâmetros g_i podem ser calculados independentemente uns dos outros de forma direta:

$$g_i = \frac{w_i^T y}{w_i^T w_i} \quad (5)$$

5.1.2.2. O Critério ERR (Error Reduction Ratio) A grande vantagem da ortogonalização é que a energia (variância) da saída $y^T y$ pode ser decomposta como a soma das contribuições individuais de cada regressor ortogonal mais a variância do resíduo:

$$y^T y = \sum_{i=1}^M g_i^2 w_i^T w_i + \Xi^T \Xi \quad (6)$$

A partir disso, define-se a **Razão de Redução do Erro (ERR)** para o i -ésimo regressor como:

$$ERR_i = \frac{g_i^2 w_i^T w_i}{y^T y} \quad (7)$$

O ERR_i quantifica, em termos percentuais (0 a 100%), o quanto aquele regressor específico é capaz de reduzir a variância do erro do modelo.

O Algoritmo Iterativo Passo a Passo O FROLS constrói a matriz W e seleciona os termos seguindo o procedimento:

- (1) **Passo 1:** Para todos os M regressores candidatos da matriz P , define-se $w_1^{(i)} = p_i$. Calcula-se o $g_1^{(i)}$ e o correspondente $ERR_1^{(i)}$. O regressor que apresentar o **maior** ERR é selecionado como o primeiro termo do modelo (w_1).
- (2) **Passo k ($k \geq 2$):** Para os regressores restantes, o algoritmo remove a parcela correlacionada com os termos já selecionados utilizando o procedimento de Gram-Schmidt modificado:

$$w_k^{(i)} = p_i - \sum_{j=1}^{k-1} \alpha_{jk}^{(i)} w_j \quad (8)$$

Onde $\alpha_{jk}^{(i)} = \frac{w_j^T p_i}{w_j^T w_j}$. Novamente, calcula-se o $ERR_k^{(i)}$ para os candidatos modificados e incorpora-se ao modelo aquele com o maior valor.

- (3) **Critério de Parada:** O processo se repete até que a soma acumulada dos ERs atinja um limiar desejado (ex: $\sum ERR > 0.999$) ou até que critérios baseados em teoria da informação (como AIC ou BIC) comecem a penalizar o ganho de complexidade.

Ao final, os parâmetros originais θ são recuperados resolvendo o sistema triangular $A\theta = g$. O resultado é um modelo com número mínimo de termos, imune a problemas de colinearidade e computacionalmente eficiente.

5.2 Regressão Ridge após Lasso

Esta abordagem consiste em uma estratégia híbrida sequencial que combina as propriedades de regularização L_1 (Lasso) e L_2 (Ridge). O objetivo é separar de forma clara a redução de dimensionalidade do tratamento da multicolinearidade.

No primeiro estágio, o Lasso atua como um filtro de seleção de variáveis, resolvendo o problema de otimização caracterizado pela penalização da norma L_1 :

$$\hat{\beta}_{\text{Lasso}} = \arg \min_{\beta} \left\{ \frac{1}{2N} \|y - X\beta\|_2^2 + \lambda_1 \|\beta\|_1 \right\} \quad (9)$$

Onde X é a matriz de desenho, y é o vetor de respostas e $\lambda_1 > 0$ é o hiperparâmetro de regularização. A geometria da norma L_1 força os coeficientes de variáveis redundantes a zero, resultando em um modelo esparso. Define-se então um subconjunto de índices ativos $\mathcal{S}$ contendo apenas os preditores selecionados (*screenout*).

No entanto, caso os preditores retidos sejam correlacionados, os coeficientes do Lasso podem apresentar alta variância. Para mitigar esse efeito, o segundo estágio aplica o estimador Ridge exclusivamente sobre a submatriz reduzida $X_{\mathcal{S}}$, utilizando a penalidade L_2^2 :

$$\hat{\beta}_{\text{Híbrido}} = \arg \min_{\beta_S} \left\{ \frac{1}{2N} \|y - X_S \beta_S\|_2^2 + \lambda_2 \|\beta_S\|_2^2 \right\} \quad (10)$$

A solução analítica para esta segunda etapa é dada por:

$$\hat{\beta}_{\text{Híbrido}} = (X_S^T X_S + 2N\lambda_2 I)^{-1} X_S^T y \quad (11)$$

A adição do termo $2N\lambda_2 I$ garante que a matriz resultante seja estritamente inversível, suavizando a distribuição dos pesos entre variáveis colineares e controlando de forma ótima o balanço entre viés e variância (*bias-variance tradeoff*).

5.3 SVR (Support Vector Regression) e Otimização Híbrida

O Princípio de Regressão da SVR A SVR busca estimar uma função contínua que se ajuste aos dados criando um "tubo de insensibilidade" com raio ε . O algoritmo ignora pequenos desvios que ocorrem dentro desse tubo e penaliza apenas os erros que caem fora dele. O objetivo principal é encontrar a função mais plana (suave) possível que não ultrapasse esse limite de erro. Para lidar com relações complexas e não lineares, a SVR utiliza uma função de Kernel (como o RBF) que mapeia os dados originais para um espaço de características de alta dimensão, permitindo que o modelo defina o formato da curva com base apenas nos pontos mais críticos (os vetores de suporte).

Hiperparâmetros Otimizados pelo Algoritmo Genético

Como a modelagem dinâmica via NARX exige tanto o ajuste do modelo estatístico quanto a seleção das defasagens no tempo (lags), o Algoritmo Genético (AG) foi projetado para atuar como um mecanismo de busca global. Cada "indivíduo" (solução) carrega um cromossomo que define:

- **C (Gene 0):** O parâmetro de penalidade da SVR. Ele controla o balanço entre manter o modelo simples e tolerar erros fora do tubo. O AG busca valores no intervalo de $[0.1, 50.0]$.
- **γ (Gene 1):** O coeficiente do kernel RBF, que define a área de influência de cada vetor de suporte. A busca ocorre no intervalo de $[0.0001, 1.0]$.
- **ε (Gene 2):** A largura do tubo de insensibilidade da SVR, definindo a margem de erro ignorada pelo modelo. A busca ocorre no intervalo de $[0.001, 0.1]$.
- **Lags Autoregressivos (y_{lag}):** Um vetor de genes binários (0 ou 1) que funciona como um interruptor para selecionar exatamente quais horas do passado da própria Carga serão incluídas no modelo.
- **Lags Exógenos (x_{lag}):** Outro vetor binário que determina quais defasagens da variável de Tempo (Hora) carregarão informação útil para o estimador.

Parametrização e Mecânica do Algoritmo Genético O AG foi configurado utilizando a biblioteca PyGAD para maximizar o coeficiente de determinação (R^2) das previsões em uma janela de teste. Para evitar modelos instáveis, penalizações severas são aplicadas a indivíduos que resultem em previsões divergentes (retornando um *fitness* negativo).

A evolução da busca segue os seguintes parâmetros operacionais:

- **População e Duração:** Uma população de 20 soluções candidatas (indivíduos) evolui ao longo de 15 gerações.
- **Seleção e Elitismo:** Em cada geração, 10 pais são selecionados via método *Steady-State* para reprodução. Os 2 melhores indivíduos de cada rodada sofrem elitismo e passam intactos para a próxima geração, garantindo que a melhor solução nunca seja perdida.
- **Cruzamento e Mutação:** A reprodução ocorre por cruzamento de ponto único (*single-point*). Para manter a diversidade no espaço de busca e evitar mínimos locais, aplica-se uma mutação aleatória que altera 10% dos genes dos novos indivíduos criados.

6. MÉTRICAS DE AVALIAÇÃO

Para avaliar e comparar quantitativamente a acurácia das previsões estáticas e das simulações autorregressivas, foram adotadas três métricas clássicas de desempenho:

O Erro Absoluto Médio (MAE), que quantifica a magnitude média dos erros absolutos de previsão:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (12)$$

A Raiz do Erro Quadrático Médio (RMSE), que penaliza de forma mais severa desvios de grande magnitude (erros discrepantes):

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (13)$$

E o Coeficiente de Determinação (R^2), que indica a proporção da variância da carga real que é explicada pelas variáveis predictoras do modelo:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (14)$$

7. RESULTADOS




Figura 4. Resultados da Predição Livre Autorregressiva para uma janela de 168 horas utilizando o método de Regressão Ridge após Lasso.

Como esperado para a aplicação do método de Regressão Ridge após Lasso em um cenário de predição livre autorregressiva, observa-se uma degradação natural da precisão

ao longo do horizonte semanal. A técnica consegue acompanhar o padrão cíclico macro da curva de carga, mas sofre com a propagação contínua de erros.




Figura 5. Resultados da Predição Livre Autorregressiva para uma janela de 168 horas utilizando o método FROLS.

Avaliando o desempenho do método FROLS (*Forward Regression Orthogonal Least Squares*), nota-se uma melhoria substancial na qualidade preditiva em comparação ao modelo Ridge após Lasso. O algoritmo iterativo de seleção ortogonal demonstrou maior capacidade de mapear a dinâmica do sistema ao longo da janela de 168 horas. Consequentemente, o modelo alcançou um Coeficiente de Determinação (R^2) superior, de 0,7520.




Figura 6. Resultados da Predição Livre Autorregressiva para uma janela de 168 horas utilizando o método SVR.

O modelo SVR obteve o melhor desempenho geral na simulação autorregressiva dos três modelos bases escolhidos. A técnica demonstrou alta capacidade de generalização e robustez comparadas às técnicas mais clássicas.




Figura 7. Resultados da Predição Livre Autorregressiva para uma janela de 168 horas utilizando o método SVR com Algoritmo Genético.

Foi implementado um algoritmo genético para encontrar os hiperparâmetros ótimos do SVR, visto que ele obteve um resultado excepcional. Esta abordagem exemplifica bem as vantagens de utilização de modelos híbridos para aprendizado de máquinas.




Figura 8. Simulação de Predição Livre Autorregressiva para uma janela de 730 horas (1 mês) utilizando o método SVR com Algoritmo Genético.

Para avaliar o limite de generalização e a robustez da metodologia, foi conduzido um teste estendido projetando a carga elétrica para um horizonte de um mês à frente. O desempenho consolidou-se com um Coeficiente de Determinação (R^2) de 0,9414, evidenciando que a otimização heurística foi capaz de capturar com alta fidelidade a dinâmica macro do sistema e os padrões sazonais estendidos, e como o lag de uma semana (comparado ao lag de um dia na previsão de uma semana) foi capaz de mostrar ao modelo como a carga varia no fim de semana em relação aos dias úteis, causando uma previsão melhor que a semanal.

Tabela 2. Comparativo de Desempenho entre Modelos Preditivos (168h)

Modelo	MAE (MW)	RMSE (MW)	R^2
Ridge pós Lasso	2700.34	3216.29	0.6244
FROLS	1557.23	2374.82	0.7520
SVR	1013.22	1444.53	0.9082
SVR com GA	894.64	1201.06	0.9366

Comparação dos valores da previsão de 168 dos modelos implementados.

A síntese apresentada na Tabela 2 evidencia a clara superioridade A Tabela 2 consolida a superioridade do modelo SVR frente às abordagens lineares e ortogonais. O destaque absoluto foi a hibridização do SVR com o Algoritmo Genético (GA), que obteve os menores erros (MAE de 894.64 MW e RMSE de 1201.06 MW) e a maior capacidade explicativa (R^2 de 0.9366). Esse resultado comprova a eficácia da otimização heurística em mitigar a propagação contínua de erros na previsão de séries temporais complexas no setor elétrico.

8. CONCLUSÃO

A metodologia proposta permite avaliar de forma realista o desempenho de algoritmos de Aprendizado de Máquina aplicados ao setor elétrico. Mais do que medir a acurácia imediata (um passo à frente), a validação, simulando um horizonte completo de operação semanal (168 horas) traz fielmente o desafio prático enfrentado pelos engenheiros de planejamento energético, evidenciando as vantagens e limitações das técnicas de regularização linear.

REFERÊNCIAS

- Géron, A. (2020). *Mãos à Obra: Aprendizado de Máquina com Scikit-Learn, Keras e TensorFlow*. Alta Books, Rio de Janeiro, 2 edition.
- Grus, J. (2020). *Data Science do Zero: Noções Fundamentais com Python*. Alta Books, Rio de Janeiro, 2 edition.
- Lacerda, W.R., da Andrade, L.P.C., Oliveira, S.C.P., and Martins, S.A.M. (2020). Sysidentpy: A python package for system identification using narmax models. *Journal of Open Source Software*, 5(54), 2384. doi:10.21105/joss.02384. URL <https://doi.org/10.21105/joss.02384>.
- Müller, A.C. and Guido, S. (2016). *Introduction to Machine Learning with Python: A Guide for Data Scientists*. O'Reilly Media, Sebastopol.
- Nielsen, A. (2021). *Análise Prática de Séries Temporais: Predição com Estatística e Aprendizado de Máquina*. Alta Books, Rio de Janeiro.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, É. (2011). Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12, 2825–2830.